Cycle Ingénieur - ING1 Mathématiques Appliquées FISA

Introduction à la science des données - 2025 / 2026

Khalil BACHIRI

TP 3 - Classification Machine Learning

Ce TP a pour objectif de comprendre les différents d'algorithmes de d'apprentissage supervisé comme KNN, Decision Tree, SVM, Logistic Regression

Le travail doit être réalisé sur Jupyter Notebook. Les résultats doivent être interprétés de manière claire.

Télécharger le dataset :

https://www.kaggle.com/datasets/uciml/default-of-credit-card-clients-dataset

Exercice 1 : Préparation et analyse des données

1. Charger le dataset, afficher les premières lignes, ses dimensions, les types des variables et vérifier les valeurs manquantes.

2. Corriger les variables nécessaires en transformant Gender, les dates et la variable education.

3. Analyser la variable loan_status et étudier son lien avec le genre, l'âge et le niveau d'éducation à l'aide de statistiques et de visualisations.

4. Créer les variables dayofweek et weekend, puis analyser leur impact sur le défaut de paiement.

5. Construire le dataset final en sélectionnant les variables pertinentes, en encodant les variables catégorielles et en supprimant les modalités inutiles.

6. Définir les variables explicatives X et la variable cible y, puis normaliser les données.

Exercice 2 : Modèle KNN

1. Diviser les données en ensembles d'entraînement et de test, déterminer la meilleure valeur de K, entraîner le modèle KNN et effectuer les prédictions.

2. Évaluer les performances du modèle à l'aide de la matrice de confusion, de la précision, du recall, du F1-score et du score de Jaccard.

3. Expliquer l'impact du choix de K sur les performances du modèle.

Exercice 3 : Modèle SVM

1. Tester différents noyaux SVM, sélectionner le meilleur modèle, entraîner le modèle et effectuer les prédictions.

2. Évaluer les performances du modèle à l'aide de la matrice de confusion, du F1-score et du score de Jaccard.

3. Expliquer l'impact du choix du noyau sur les performances du modèle.

Exercice 4 : Comparaison et analyse

1. Comparer les modèles KNN, SVM et identifier le meilleur modèle.

2. Analyser les limites du dataset et des modèles utilisés et proposer des améliorations.

3. Choisir un modèle pour une utilisation réelle en banque et justifier ce choix.